

T-05 · YADYAR LITE · FINAL REPORT

تولید تقویت شده با بازیابی و مطالعه توهم در سیستم‌های RAG

Retrieval-Augmented Generation and the Study of Hallucination

مقدمه و طراحی آزمایش

Introduction and Experimental Design

این مطالعه یک baseline سبک RAG را روی نمونه ثابت SQuAD v2 ارزیابی می‌کند. سؤال اصلی این است که سیستم چه زمانی شاهد درست را بازیابی می‌کند، پاسخ درست می‌سازد و در نبود شاهد از پاسخ‌گویی خودداری می‌کند.

یافته اصلی: بازیابی در **corpus** کنترل‌شده قوی است و **FLAN-T5-base** نسبت به نسخه **small** رفتار **abstention** بهتری دارد؛ باین‌حال هنوز در ۳۰ مورد از ۴۰ سؤال بدون پاسخ، پاسخ محتوایی تولید می‌کند.

120

کل نمونه‌ها

80 / 40

قابل پاسخ / غیرقابل پاسخ

113

پاراگراف یکتا

تنظیم	انتخاب	مؤلفه
بردار نرمال‌شده	all-MiniLM-L6-v2	Embedding
Top-3 دقیق	FAISS IndexFlatIP	Retrieval
شاهد رتبه ۱، greedy	google/flan-t5-base	Generator
خروجی صریح در نبود شاهد	NO_ANSWER	Abstention

نتایج ارزیابی بازیابی

Retrieval Evaluation Results

ارزیابی بازیابی فقط روی ۸۰ سؤال قابل پاسخ انجام شد. در ۷۱ مورد شاهد مرجع در رتبه اول قرار گرفت و در ۷۹ مورد در میان سه نتیجه اول دیده شد.

88.75%


Recall@1

98.75%

Recall@3

1

خطای کامل Top-3



تفسیر: فقط یک سؤال قابل پاسخ شاهد خود را در Top-3 از دست داده است. هشت مورد بیشتر به reranking نیاز دارند؛ بنابراین تعویض کامل retriever اولویت اصلی نیست.

نتایج ارزیابی تولید

Generation Evaluation Results

50.83%


کل Exact Match

59.09%

کل Token F1

25.00%

دقت abstention




تفسیر	نتیجه	گروه
EM ثابت ماند و F1 به ۷۶٫۱۳٪ رسید	51/80 exact	قابل پاسخ
مدل هنوز ۳۰ بار پاسخ محتوایی تولید کرد	10/40 abstain	غیرقابل پاسخ
۱۰ مورد درست و یک مورد روی سؤال قابل پاسخ	11 abstentions	کل نمونه

تحلیل تفصیلی نتایج

Detailed Result Breakdown

نتیجه	F1	EM	N	گروه	برش
بهرتر از بلند	60.05%	53.73%	67	کوتاه	طول سؤال
ضعیف‌تر	57.87%	47.17%	53	بلند	طول سؤال
قوی	85.78%	71.83%	71	Hit	Top-1
سقوط کامل	0.00%	0.00%	9	Miss	Top-1




طول سؤال با اختلاف حدود 2.18 واحد F1 اثر محدودی دارد؛ اما خطای رتبه اول F1 را از 85.78% به 0.00% می‌رساند. انتخاب شاهد درست همچنان مرز اصلی عملکرد pipeline است.

تحلیل خطا و بازبینی دستی

Error Analysis and Manual Review

دسته‌بندی خودکار فقط برای triage استفاده شد. هیچ پاسخ غلطی بدون بررسی شاهد، hallucination قطعی نامیده نشد. سپس 22 نمونه منتخب و عمداً خطامحور با متن رتبه اول مقایسه شدند.



13

بی‌پشتوانه یا نامرتبط

4

نیمه‌صحیح یا اضافی

5

قابل قبول پس از بازبینی

این 22 نمونه، failure-enriched هستند؛ بنابراین سهم 59.09٪ خروجی بی‌پشتوانه فقط ویژگی این نمونه انتخاب‌شده است و نرخ کلی hallucination مدل محسوب نمی‌شود.

نمونه‌های نماینده و دمو

Representative Errors and Demo

شکست در abstention

Q: What was the name of the non-imperialistic policy in China?

Output: Open Door Policy

متن نام سیاست را می‌آورد، اما صفت non-imperialistic را پشتیبانی نمی‌کند.

نادیده‌گیری شاهد

Q: How much is the sieve method of gas production used?

Output: 90% to 93% O2

عدد مربوط به غلظت اکسیژن است، نه میزان استفاده از روش.

خطای معیار

Q: What is the main judicial body of the EU?

Output: Court of Justice of the European Union

پاسخ معنایی درست است؛ حذف acronym باعث Exact Match صفر شد.

شاهد نامرتب

Q: Which gender is more populous across all groups...?

Output: male

متن رتبه اول درباره آب‌وهواست و هیچ شاهد جمعیتی ندارد.

دموی جدید: مدل base برای پرسش ایمیل خصوصی و موعد تکلیف به درستی NO_ANSWER تولید کرد؛ اما در نمونه benchmark با similarity بالا درباره ساختمان George IV Bridge هنوز پاسخ محتوایی ساخت.

تغییر مدل، abstention را واقعاً بهتر کرد

Controlled Small-vs-Base Comparison

هر دو اجرا از همان ۱۲۰ سؤال، FAISS، embedding، corpus، seed و Prompt اصلی استفاده کردند. تنها مدل مولد از FLAN-T5-small به FLAN-T5-base تغییر کرد؛ بنابراین مقایسه، اثر ظرفیت generator را جدا می‌کند.

+7.50


تغییر EM کل

+8.43

تغییر F1 کل

+22.50

تغییر abstention غیرقابل پاسخ



مدل base در 15 نمونه EM را اصلاح و در 6 نمونه خراب کرد. هر ۹ abstention جدید روی سؤال‌های بدون پاسخ رخ داد و هیچ abstention قبلی از دست نرفت؛ Recall بازیابی نیز دقیقاً ثابت ماند.

در سؤال‌های قابل پاسخ، EM هر دو مدل ۶۳٫۷۵٪ بود و F1 فقط ۱٫۳۹ واحد بهتر شد. بنابراین بخش عمده رشد کلی از تشخیص بهتر نبود پاسخ می‌آید، نه از جهش کیفیت پاسخ‌گویی یا تغییر retriever.

آزمایش‌های امتیازی سبک

Lightweight Bonus Extensions

سه افزونه بدون تغییر baseline اجرا شد: بسته دمو تمیز، برش سه‌گانه بر اساس similarity رتبه اول، و مقایسه کنترل‌شده Prompt اصلی با Prompt سخت‌گیرانه. هر دو Prompt همان ۱۲۰ سؤال، همان شاهد رتبه اول و همان تنظیمات greedy را دریافت کردند.

Prompt سخت‌گیرانه یک trade-off کوچک و قابل اندازه‌گیری ساخت

تغییر	Prompt سخت‌گیرانه	Prompt اصلی	معیار
0.84+	51.67%	50.83%	Exact Match کل
1.50+	60.59%	59.09%	Token F1 کل
0.25-	75.88%	76.13%	Token F1 قابل پاسخ
5.00+	30.00%	25.00%	abstention غیرقابل پاسخ

از ۱۲۰ خروجی، 91 مورد بدون تغییر ماند؛ Prompt سخت‌گیرانه 4 Exact Match را اصلاح و 3 مورد را خراب کرد. abstention غیرقابل پاسخ ۵ واحد بهتر شد، اما F1 سؤال‌های قابل پاسخ 0.25 واحد کاهش یافت؛ پس نتیجه یک trade-off است، نه پیروزی مطلق.

گروه similarity پایین ضعیف‌تر بود، اما رابطه یکنواخت نیست

60.48%

F1 قابل پاسخ در گروه similarity پایین

81.90%

F1 قابل پاسخ در گروه similarity متوسط

80.80%

F1 قابل پاسخ در گروه similarity بالا

هر گروه ۴۰ نمونه داشت، اما ترکیب answerability آن‌ها یکسان نبود؛ بنابراین اعداد بالا فقط برای سؤال‌های قابل پاسخ گزارش شده‌اند. این رابطه توصیفی است و similarity یک confidence score کالیبره یا threshold آماده نیست.

بسته دمو قابل اجرا

دمو شامل شش ورودی آماده، پاسخ هر دو Prompt، تصمیم abstention، منبع و similarity است. هر دو Prompt در پرسش ایمیل خصوصی و موعد تکلیف «NO_ANSWER» تولید کردند. در دو نمونه benchmark بدون پاسخ، هر دو مدل روی نمونه کم‌شباهت abstain کردند و روی نمونه پُرشباهت پاسخ محتوایی ساختند. ورودی‌های سفارشی در metric‌های SQuAD محاسبه نشده‌اند.

محدودیت‌ها، کار آینده و یکپارچه‌سازی

Limitations, Future Work, and Integration

محدودیت‌ها

- نمونه کوچک، کنترل‌شده و انگلیسی است و عملکرد روی اسناد واقعی درسی یا پرسش‌های فارسی را اثبات نمی‌کند.
- EM و F1 پشتیبانی شواهد را مستقیماً اندازه نمی‌گیرند.
- فقط شاهد رتبه اول به FLAN-T5-base داده می‌شود و هیچ reranking یا support gate وجود ندارد.
- هیچ مقایسه علی با no-RAG یا تعمیم آماری ادعا نمی‌شود.
- افزودن reranker سبک برای هشت نمونه‌ای که شاهد درست در رتبه دوم یا سوم است.
- افزودن entailment یا claim-support gate: Prompt سخت‌گیرانه فقط ۵ واحد abstention را بهتر کرد و هنوز ۲۸ سؤال بدون پاسخ را از دست داد.
- تنظیم threshold روی validation جداگانه، نه روی نتایج test.

قرارداد یکپارچه‌سازی آینده

ورودی	خروجی
question: string; top_k: 3	answer / NO_ANSWER; abstained; source_title; source_context_id; retrieval_similarity

جمع‌بندی: FLAN-T5-base نسبت به small، EM و F1 کلی و به‌ویژه abstention را به‌طور روشن بهتر کرد؛ اما baseline اصلی هنوز در ۳۰ مورد از ۴۰ سؤال غیرقابل‌پاسخ پاسخ می‌سازد. Prompt سخت‌گیرانه این عدد را فقط به ۲۸ کاهش داد؛ اولویت بعدی evidence-support gate است.

منابع: Hugging Face SQuAD v2، all-MiniLM-L6-v2، FLAN-T5-base، Rajpurkar et al. (2018)، مستندات FAISS و داگ YadYar Lite. استفاده از دستیار هوش مصنوعی برای ساختاردهی کد، بازبینی مستندات، گزارش و اسلایدها اعلام می‌شود.