

T-05 · YADYAR LITE · PHASE 1

تولید تقویت شده با بازیابی و مطالعه توهم در سیستم‌های RAG

Retrieval-Augmented Generation and the Study of Hallucination

مقدمه و صورت مسئله

Introduction and Problem Statement

این پروژه یک پایپ‌لاین سبک RAG را در یک مجموعه کنترل‌شده بررسی می‌کند. هدف ساخت محصول یا آموزش مدل جدید نیست؛ بلکه می‌خواهیم ببینیم سیستم چه زمانی شاهد درست را پیدا می‌کند، چه زمانی پاسخ درست می‌دهد و در نبود شاهد آیا می‌تواند از پاسخ‌گویی خودداری کند.

سؤال پژوهشی محدود: یک baseline سبک RAG در SQuAD v2 با چه دقتی پاسخ می‌دهد و خطاها از بازایی، تولید یا شکست در abstention ناشی می‌شوند؟

دیتاست و نمونه‌گیری

داده از بخش validation دیتاست SQuAD v2 گرفته شد. نمونه با seed ثابت ۴۲ ساخته شد تا اجرای مجدد همان پرسش‌ها را انتخاب کند. سؤال‌های بدون پاسخ برای سنجش abstention ضروری‌اند.

ویژگی	مقدار	کاربرد
منبع	SQuAD v2 validation	دیتاست عمومی پرسش‌پاسخ
کل validation	11,873	دامنه اصلی داده
نمونه ارزیابی	120	کوچک و قابل بررسی
قابل پاسخ	80	ارزیابی بازایی و تولید
غیرقابل پاسخ	40	ارزیابی خودداری از پاسخ
پاراگراف یکتا	113	Corpus بازایی

مدل پایه و معماری سیستم

Baseline Model and System Architecture



نقش	مدل / ابزار	مؤلفه
بردارسازی متراکم و نرمال شده	all-MiniLM-L6-v2	Embedding
جست و جوی دقیق Top-3	FAISS IndexFlatIP	Retrieval
تولید فقط از شاهد رتبه ۱	google/flan-t5-base	Generation
خروجی مورد انتظار در نبود شاهد	NO_ANSWER	Abstention
بدون fine-tuning یا آموزش	None	Training

قاعده پرامپت: پاسخ فقط از متن بازیابی شده تولید شود؛ اگر شاهد کافی وجود ندارد، خروجی دقیقاً NO_ANSWER باشد.

بازآفرینی و کنترل اولیه

Reproducibility and Sanity Checks

6/6

پرسش‌های کنترل اجرا شد

5/6

شاهد درست در رتبه 1

6/6

شاهد درست در Top-3

فاز اول فایل سؤال‌ها، embedding، corpus، ایندکس FAISS، تنظیمات و خروجی‌های کنترل را ذخیره می‌کند. فاز دوم همین artifact‌ها را بارگذاری می‌کند؛ بنابراین baseline بین دو فاز تغییر نمی‌کند.

نتیجه	Top-1	نمونه
پاسخ معنایی صحیح با حذف acronym	Hit	What is the main judicial body of the EU?
به‌جای abstain پاسخ تولید شد	Hit	What was the name of the non-imperialistic policy in China?

کنترل اولیه نشان داد مسیر کامل اجرا می‌شود؛ اما نمونه غیرقابل‌پاسخ از همان ابتدا ضرورت تحلیل abstention را آشکار کرد.

برنامه ارزیابی و تحلیل خطا

Evaluation and Error-Analysis Plan

بخش	تعریف
Exact Match	تطابق کامل پاسخ نرمال شده با یکی از پاسخ های مرجع
Token F1	همپوشانی توکنی با بهترین پاسخ مرجع
Answerability	مقایسه سؤال های قابل پاسخ و غیرقابل پاسخ
Question Length	مقایسه سؤال های کوتاه و بلند
Retrieval	مقایسه Hit و Miss در رتبه اول
Manual Review	بازبینی خطاهای بازیابی، شواهد غایب، نادیده گیری شاهد و پاسخ ناقص

- EM و F1 کیفیت پاسخ را می سنجند، اما به تنهایی پشتیبانی شواهد را اثبات نمی کنند.
- هر پاسخ غلط نباید خودکار hallucination نامیده شود؛ موارد منتخب باید با متن شاهد بازبینی شوند.
- آزمایش در یک corpus کوچک انگلیسی انجام می شود و ادعای تعمیم به اسناد واقعی آموزشی ندارد.
- مقایسه علی با سیستم بدون RAG، آزمون آماری و fine-tuning در محدوده الزامی پروژه نیست.

منابع و اعلام استفاده از هوش مصنوعی

منابع اصلی: SQuAD v2، مدل all-MiniLM-L6-v2، مدل FLAN-T5-base، مستندات FAISS و داگ YadYar Lite. از دستیار هوش مصنوعی برای ساختاردهی کد و مستندات استفاده شده است؛ مسئولیت اجرای آزمایش و دفاع از تمام اعداد بر عهده تیم است.